

Virtual Try-on

*Nghiên cứu các mô hình thử đồ ảo, lựa chọn một mô hình để tiến hành khảo sát, đánh giá và đề xuất hướng cải tiến.

1st Thi Gai Nguyen
dept. Information Technology
University of Science, HCMC
Ho Chi Minh city, Vietnam
ntgai1905@gmail.com

2nd Doan Khoi Phung
dept. Information Technology
University of Science, HCMC
Ho Chi Minh city, Vietnam
doankhoi0412@gmail.com

3rd Bao Huy Van Ba
dept. Information Technology
University of Science, HCMC
Ho Chi Minh city, Vietnam
baohuyvanba@gmail.com

Tóm tắt nội dung—Virtual Try-on là công nghệ cho phép thử trang phục lên trên hình ảnh hoặc video con người. Virtual Try-on đóng vai trò quan trọng trong việc nâng cao trải nghiệm mua sắm trực tuyến của người dùng. Công nghệ này được phát triển với nhiều phương pháp và hướng tiếp cận khác nhau. Trong bài viết bên dưới trình bày khảo sát những phương pháp sử dụng hướng tiếp cận dựa trên hình ảnh (Image-based). Bài báo cáo đề xuất mô hình CP-VTON bao gồm 2 bước: Geometric Matching Module (GMM) nhằm xử lý được sự lệch không gian lớn giữa hình ảnh đầu vào và trang phục mục tiêu và Try-On Module dùng để tăng tính chân thực của kết quả.

Index Terms—virtual try-on, image-based, CP-VITON

I. GIỚI THIỆU

A. Động lực nghiên cứu

Trong bối cảnh thương mại điện tử phát triển bùng nổ và xu hướng mua sắm trực tuyến trở nên phổ biến, việc cung cấp trải nghiệm mua hàng tốt nhất cho khách hàng là ưu tiên hàng đầu. Điều này đặc biệt quan trọng trong lĩnh vực thời trang, khi người dùng quan tâm tới việc sản phẩm có phù hợp với vóc dáng, phong cách của bản thân hay không. Do đó, công nghệ Virtual Try-on ra đời để nâng cao trải nghiệm người dùng, cung cấp cho họ một trải nghiệm mua sắm chân thực khi có thể dễ dàng "ướm" sản phẩm lên cơ thể, hình dung sản phẩm khi mặc vào, từ đó tăng khả năng hài lòng và tin tưởng, thúc đẩy lượng mua và giảm tỷ lệ đổi trả hàng. Từ đó đến nay, công nghệ này đã phát triển không ngừng với sự ra đời của nhiều phương pháp và mô hình nhằm cải thiện độ chính xác, mức độ chân thực.

B. Phát biểu bài toán

Phát biểu tổng quan cho mô hình Virtual Try-on:

Input

- I_p : Hình ảnh hoặc mô hình 3D của người dùng. Đại diện cho dữ liệu về người dùng, bao gồm thông tin về hình dáng và kích cỡ của họ.
- I_c : Hình ảnh hoặc mô hình 3D của quần áo cần áp dụng lên người dùng. Đại diện cho dữ liệu về quần áo, bao gồm cả thông tin về cấu trúc và vật liệu của quần áo.

Output

- $I_{try_on} = f(I_p, I_c)$: Hình ảnh hoặc video người dùng với trang phục được đưa vào.

Mục tiêu: Tạo ra hình ảnh hoặc video thử đồ chân thực và tự nhiên bằng cách ghép trang phục từ hình ảnh I_c vào người mẫu trong hình ảnh I_p . Hình ảnh thử đồ cần phản ánh đúng về vị trí, hình dạng, và kích thước của quần áo trên người dùng.

C. Phương pháp tiếp cận

Các phương pháp Virtual Try-on có thể được chia thành ba loại: mô phỏng dựa trên vật lý (Physical-based simulation), thu thập thực tế (Real acquisition) và tạo hình ảnh (Image generation). Hiện nay với sự phát triển của tạo sinh ảnh thì phương pháp thử đồ ảo dựa trên hình ảnh (Image-based Virtual Try-on) trở nên hấp dẫn vì hiệu quả cao và chi phí thấp hơn.


Bài viết sau đây sẽ trình bày về mô hình thuộc phương pháp thử đồ ảo dựa trên hình ảnh. Các công trình nghiên cứu liên quan được đưa ra nhằm mục đích phân loại rõ hơn về các mô hình trong nhóm phương pháp tiếp cận này.

II. CÁC CÔNG TRÌNH NGHIÊN CỨU LIÊN QUAN

A. Cycle GAN Structure

Mô hình DCTON [1] được đề xuất năm 2021 là một mô hình có cấu trúc Cycle GAN nhằm tái tạo hình ảnh đầu vào bằng cách tự giám sát. Mô hình khắc phục khuyết điểm của các mô hình hiện tại khi không thể phân biệt được vùng có chứa trang phục hoặc không. DCTON có thể tạo ra các hình ảnh thử có độ chân thực cao bằng cách gỡ rối các thành phần quan trọng của virtual try-on bao gồm độ cong vênh của quần áo, tổng hợp da và kết hợp tổng thể.

- Đầu tiên, sử dụng Densepose descriptor để trích xuất biểu diễn bề mặt con người, gọi là D . Mạng encoder-decoder có tên MPN(mask prediction networks) sẽ dùng D và C_2 (quần áo trong cửa hàng) để tạo ra mặt nạ cho vùng quần áo $M_1^{clothes}$ và vùng da M_1^{skin} .
- Mạng STN(spatial transformer network) được dùng để tạo hình ảnh cong vênh cho quần áo dựa trên đầu vào $M_1^{clothes}$ và C_2 . Cụ thể, STN sẽ tạo ra ma trận



Hình 1. Tổng quát mô hình DCTON


biến đổi $\mathcal{T}$ và hướng dẫn nó thông qua TPS(Thin-Plate Spline).

- Sự tổng hợp da nhằm mục đích phục hồi phần cơ thể bị che đi. DCTON sử dụng bề mặt đầu vào D để trích xuất ra vùng da S_1 và sử dụng CNN để nắm bắt các đặc trưng của nó.
- Kết quả thử đồ I_2 sẽ được tạo ra từ bộ (D, C_2, S_1, I_1) . Sau đó, $\bar{I}_1$ sẽ được dự đoán ngược lại từ bộ (I_2, S_2, C_1, D) . Sự nhất quán chu kỳ được thiết lập bằng cách ép buộc $\bar{I}_1 \approx I_1$ để xây dựng sự tự giám sát.

B. Teacher-Student Structure

Mô hình SAL-VTON [2] được đề xuất năm 2023 là một mô hình có cấu trúc Teacher-Student. Mô hình không yêu cầu phân tích cú pháp (parse free) về cấu trúc của các yếu tố trong hình ảnh như khuôn mặt, quần áo, hoặc vùng quan trọng khác. Dựa trên các điểm địa danh có liên quan ngữ nghĩa, SAL-VTON hiệu quả mô hình hóa mối liên kết ngữ nghĩa cục bộ giữa trang phục và người, bù đắp cho việc không đồng bộ trong biến dạng tổng thể của trang phục. Mô hình bao gồm 3 giai đoạn: 1) ước lượng các điểm mốc có liên quan ngữ nghĩa, 2) từ các điểm mốc liên kết các phần tương ứng của trang phục và người để thu được luồng cục bộ, từ đó tinh chỉnh sự đồng bộ trong luồng toàn cục, 3) nắm bắt ngữ nghĩa cục bộ và kiểm soát kết quả thử đồ.

- HRNET được sửa đổi để ước tính các điểm mốc liên quan. Đầu vào là trang phục G và người P_0 đang mặc các trang phục khác. Đầu ra L_p chỉ ra các vị trí mà các điểm mốc L_g sẽ xuất hiện trong kết quả thử đồ cuối cùng.
- Hai trích xuất đặc trưng FPN (Feature Pyramid Network) được dùng để tạo ra hình ảnh cong vênh cho trang phục. Thông qua luồng toàn cầu, trang phục G được biến dạng thành W_g để phù hợp với hình dạng của cơ thể người. Luồng cục bộ tập trung vào mối liên kết cục bộ cụ thể giữa trang phục và người để tạo ra W_l . Sự kết hợp giữa 2 luồng cho ta kết quả W_f giảm thiểu sự không đồng bộ và cải thiện kết quả.




Hình 2. Tổng quát mô hình SAL-VTON

- Các đầu ra từ các giai đoạn trước đó (W_g, W_l, W_f) và người P_0 được hướng dẫn bởi heatmap của điểm mốc L_p để tạo ra ảnh thử đồ cuối cùng P_g . LASNL (Landmark-Aware Semantic Normalization Layer) được áp dụng cho L_p để xác định xem các khu vực cục bộ của người P_0 có cần mặc trang phục không và giảm thiểu sự không đồng bộ cục bộ.

C. Multi-Garment Try-On

Được đề xuất lần đầu năm 2021, mô hình Dressing in Order hay DiOr [3] với khả năng thực hiện các chuyển đổi tư thế người trên ảnh 2D, thử đồ ảo (virtual try-on) và các tác vụ chỉnh sửa liên quan đến thời trang khác. Đối với khả năng thử đồ ảo, khả năng then chốt của mô hình này là việc thay đổi tuần tự trang phục trên ảnh người theo thứ tự trang phục đưa vào, từ đó tạo ra những kết quả đầu ra khác biệt. Mô hình này có thể thực hiện những công việc mà các phương pháp tại thời điểm đó chưa thể thực hiện, bao gồm trong đó là các tương tác khác nhau với trang phục (là việc mặc áo có thể bỏ vào trong quần hoặc mặc phủ bên ngoài) và việc mặc xếp theo từng lớp các trang phục tại cùng vùng cơ thể mục tiêu (thay đổi áo thun, sau đó phủ áo khoác lên bên ngoài). Các tiếp cận khác đều thực hiện việc tạo ra bản đồ phân đoạn trang phục và tạo sinh toàn bộ trong một bước duy nhất, và do đó chỉ có duy nhất một kết quả được tạo ra với một tập trang phục đầu vào và được xác định bởi mô hình. Tuy nhiên, trên thực tế, con người mặc từng quần/áo một và xếp chúng theo các lớp khác nhau và mô hình DiOr được đưa ra ở bài viết này kết hợp các mô-đun tái tạo để tạo ra các kiểu dáng khác nhau tùy thuộc theo thứ tự trang phục được đưa vào.

- Dữ liệu con người được biểu diễn dưới dạng một bộ dữ liệu $(pose, body, \{garments\})$.
- Quá trình tạo sinh bắt đầu với việc mã hóa tư thế mục tiêu dưới dạng Z_{pose} và cơ thể con người ban đầu dưới dạng bản đồ cấu trúc T_{body} .




Hình 3. Tổng quát mô hình DiOr - Dressing in Order

- Khi đó, cơ thể mã hóa Z_{body} được tạo ra bởi mô-đun tạo sinh G_{body} .
- Khi đó, Z_{body} trở thành đầu vào cho bộ tạo sinh trang phục G_{gar} trong chu trình lặp lại. Các bộ tạo sinh này có các đầu vào là trang phục theo thứ tự xác định được mã hóa bởi các bản đồ đặc trưng 2D T_{gk} và một mặt nạ hình dáng M_{gk} .
- Ngoài ra, các bộ mã hóa E_{body} và E_{gar} sử dụng các luồng ước tính f để điều chỉnh cơ thể ban đầu và các trang phục theo đúng như tư thế mục tiêu. Và đồng thời quá trình trên có thể thực hiện giải mã bằng G_{dee} để có thể thấy được kết quả đầu ra ở từng giai đoạn.

D. High Resolution

Mô hình VITON-HD [4] được đề xuất năm 2021 dựa trên VITON [5], mô hình nhằm mục đích khắc phục việc các phương pháp tiếp cận tại thời điểm đó không thể tạo ra hình ảnh tổng hợp từ hình ảnh người và trang phục đạt được chất lượng ảnh cao. Đồng thời mô hình áp dụng một bộ chuẩn hóa ALIAS mà nhờ đó loại bỏ các thông tin sai lệch của các vùng lệch giữa trang phục được điều chỉnh với vùng mục tiêu và bảo toàn thông tin ngữ nghĩa.




Hình 4. Tổng quát mô hình VITON-HD

- Đầu tiên, với hình ảnh đầu vào I là hình ảnh của con người mục tiêu (người cần thay trang phục), mô hình ước tính bản đồ phân đoạn S và bản đồ tư thế P . Sau đó, sử dụng chúng để tiền xử lý hình ảnh I và bản đồ phân đoạn S thành một hình ảnh người không mang thông tin trang phục I_a và phân đoạn S_a .
- Tiếp theo, bộ tạo sinh phân đoạn tạo ra phân đoạn tổng hợp $\hat{S}$ từ bộ dữ liệu (S_a, P, c) .

- Mô-đun kết hợp hình học điều chỉnh ảnh trang phục c dựa theo việc ước tính bản đồ phân đoạn trang phục $\hat{S}_c$ trích xuất từ $\hat{S}$.
- Cuối cùng, bộ tạo sinh ALIAS tổng hợp đầu ra cuối cùng, hay ảnh $\hat{I}$ từ các quá trình trước thông qua bộ chuẩn hóa ALIAS.

E. Implicit Transformation

Các mô hình thuộc về dạng này sẽ không giải thích rõ quá trình chuyển đổi trên miền không gian ảnh nhưng vẫn tạo ra ảnh cần thiết. Trong đó, có mô hình Try-on Diffusion [6] được đề xuất năm 2023 thuộc mô hình Diffusion đang là mô hình hiện đại nhất trong các mô hình tạo sinh. Điểm đặc biệt là mô hình giới thiệu mạng mới Parralel-Unet Diffusion giúp việc thực thi tác vụ thử ảo hiệu quả hơn.




Hình 5. Tổng quát mô hình Try-on Diffusion

Các bước thực hiện của mô hình Try-on Diffusion:

- Biểu diễn của con người được loại bỏ thông tin về trang phục (clothing-agnostic person representation) và ảnh trang phục được đưa vào mô hình 128x128 Parralel-Unet Diffusion để tạo ra ảnh thử trang phục I kích thước 128x128. Đây là bước quan trọng nhất.
- Sau đó, ảnh I được đưa qua mạng 256x256 Parralel-Unet Diffusion để tạo ảnh có kích thước 256x256. Sau đó lại qua một mạng Super-Resolution Diffusion để tạo ảnh chất lượng cao có kích thước 1024x1024.

F. Other

Mô hình thử đồ ảo (Virtual Try-on) VITON [5] được ra mắt vào năm 2018. Ý tưởng của mô hình là tạo ra vùng ảnh trang phục mong muốn trên ảnh, sau đó mới làm rõ các chi tiết có trên trang phục để tạo ra ảnh hoàn chỉnh (Coarse-to-fine strategy) được thể hiện trong hình 6. Mô



Hình 6. Tổng quát mô hình VITON

hình được xem là tiên phong cho các nghiên cứu sau này trong lĩnh vực Virtual Try-on.

Mô hình bao gồm 2 bước chính là Encoder-Decoder Genator và giai đoạn tinh chỉnh (Refinement Stage):

- Dữ liệu đầu vào là dữ liệu về con người bao gồm ảnh người RGB, đặc trưng tư thế, ảnh mặt và tóc (không chứa thông tin trang phục), ảnh nhị phân về dáng người đi kèm với ảnh trang phục ta muốn thử C . Sau đó, ta đi qua mạng Encoder-Decoder, cụ thể là mạng U-net sử dụng kỹ thuật Skip connections để tạo ra ảnh thô (I') chứa vùng trang phục trên người và ảnh nhị phân chứa vùng trang phục (M).+
- Với ảnh trang phục mục tiêu (C), ta điều chỉnh cho có kiểu dáng phù hợp với ảnh nhị phân M có được ở bước trước nhờ sử dụng Shape Context Matching và được ảnh trang phục đã chỉnh C' . Sau đó kết hợp I' và C' được ảnh kết quả cuối cùng.

G. Comparison

Các công trình nghiên cứu trên là những công trình nghiên cứu đại diện cho những hướng tiếp cận khác nhau thuộc nhóm phương pháp thử đồ ảo dựa trên hình ảnh (Image-based Virtual Try-on). Bảng I so sánh các mô hình mạng được sử dụng cho các tác vụ cụ thể trong Virtual Try-on và các đóng góp mà những nghiên cứu này mang lại cho lĩnh vực trên dựa theo những khảo sát [7] và [8].

III. PHƯƠNG PHÁP

A. Đề xuất phương pháp

Mua sắm trực tuyến mang lại nhiều lợi thế thương mại so với mua sắm truyền thống (thời gian, giá cả, tiện lợi, ...), tuy nhiên phương pháp này thiếu đi trải nghiệm cảm nhận sản phẩm trực tiếp hay cụ thể là việc có thể thử đồ trực tiếp và từ đó đưa ra quyết định mua sắm. Công nghệ

thử đồ ảo (Virtual Try-on hay VTON) ra đời nhằm giải quyết vấn đề này, nó cung cấp trải nghiệm tương tự như thử đồ trực tiếp, giúp người dùng dễ dàng đánh giá sản phẩm và đưa ra quyết định mua hàng, từ đó nâng cao hiệu quả cho nhà bán hàng.

Các mô hình truyền thống sử dụng đồ họa máy tính để xây dựng mô hình 3D và tạo ra kết quả mong muốn vì phương pháp đồ họa sẽ cung cấp một cách kiểm soát chính xác các phép biến đổi hình học và các ràng buộc vật lý. Tuy nhiên nó lại gây ra khó khăn trong việc thực thi cũng như yêu cầu các thiết bị tính toán mạnh mẽ. Khi đó, VTON với tiếp cận dựa trên hình ảnh không sử dụng thông tin 3D, tiết kiệm chi phí và mang lại kết quả hứa hẹn. Các mô hình VTON dựa trên hình ảnh có mục tiêu tạo ảnh mới với người mặc trang phục mới được đưa vào, giữ nguyên hình dáng và tư thế con người, đồng thời với trang phục chân thực, mượt mà, giữ nguyên đặc trưng của quần áo. Lúc này, các mô hình VTON cần đảm bảo các yêu cầu như sau: (1) Hình ảnh người được thay đổi với trang phục mục tiêu, (2) Tư thế và hình dáng được bảo toàn, (3) Trang phục được "ướm" vào có độ chân thực cao, và (4) Đặc trưng của trang phục được bảo toàn. Các tiếp cận thời điểm đó sử dụng các mất mát pixel-to-pixel (mất mát L1, L2), mất mát perceptual, adversarial tuy nhiên vẫn còn các sai lệch các thông tin quan trọng.

Năm 2017, mô hình thử đồ ảo VITON [5] được đưa ra, mô hình này không dựa vào các thông tin 3D mà liên mạch chuyển đổi trang phục mục tiêu vào trên vùng mong muốn của ảnh người được đưa vào. Sử dụng hướng tiếp cận chung, tổng quát và sau đó sử dụng kết quả đó để tăng chất lượng ở kết quả đầu ra (Coarse-to-fine strategy). Kể từ đó, hàng loạt mô hình thử đồ ảo dựa trên hình ảnh cũng được đưa ra, một trong số đó là mô hình Characteristic-Preserving Image-based Virtual Try-On Network hay gọi là CP-VTON. Mô hình CP-VTON khắc phục điểm yếu trong việc bảo toàn các đặc trưng của trang phục (cấu trúc, logo, chữ, ...) như việc so sánh được đưa ra trong Hình 7.

B. Tổng quan về phương pháp

Mô hình thử đồ ảo (Virtual Try-on) bao gồm các đầu vào và đầu ra như sau:

- Đầu vào của mô hình:
 - 1) Ảnh tham chiếu (reference image): $I \in \mathbb{R}^{3 \times H \times W}$
 - 2) Ảnh trang phục (clothing image): $c \in \mathbb{R}^{3 \times H \times W}$
- Đầu ra của mô hình là hình ảnh tổng hợp (synthetic image) $\hat{I} \in \mathbb{R}^{3 \times H \times W}$, với các thông tin được bảo toàn bao gồm:
 - 1) Tư thế và hình dáng cơ thể của hình ảnh I .
 - 2) Chi tiết trên trang phục trong ảnh c .


Mô hình CP-VTON được đưa ra nhằm khắc phục các vấn đề của các mô hình được đưa ra trước thời điểm đó, cụ thể là việc các mô hình đó không thể đạt được những yêu cầu quan trọng được đưa ra ở trên trong quá trình hướng tới một hiệu suất hợp lý vì chúng không thể xử lý

Bảng I
BẢNG SO SÁNH CÁC PHƯƠNG PHÁP THỬ ĐỒ ẢO ĐƯỢC ĐỀ CẬP

Model	Year	Network type	Warping method	Contribution
DCTON	2021	GAN	TPS	Giới thiệu phương pháp rời rạc các tác vụ của Virtual try-on theo một vòng lặp có tính nhất quán dựa trên mô hình CAGAN.
SAL-VTON	2023	U-net	Multi-FlowNet	Không cần phải phân tích bố cục người (parser free) mà dựa vào các điểm mốc giúp việc xử lý đơn giản hơn
DiOr	2017	n/a	FlowNet	Khả năng thay đổi tuần tự theo thứ tự trang phục đưa vào, điều mà các mô hình khác chưa làm được.
VITON-HD	2021	U-net	TPS	Nâng cấp của VITON, Giới thiệu ALIAS để khắc phục sai lệch giữa ảnh trang phục đã điều chỉnh hình dạng và vùng ảnh trang phục của ảnh người mục tiêu.
TryOnDiffusion	2022	Diffusion Model	n/a	Giới thiệu mô hình tiên tiến sử dụng Diffusion trong đó xài mạng Parralel U-net, tăng độ phân giải và tính chân thực của ảnh thử đồ.
VITON	2018	U-net	TPS	Tạo mô hình Encoder-Decoder sử dụng U-net để đưa ra ảnh mẫu thô sau đó tiếp tục nâng cao chất lượng ảnh, tiên phong cho các nghiên cứu sau này.



Hình 7. So sánh kết quả đầu ra các mô hình



Hình 8. Cấu trúc mô hình CP-VTON

các sai lệch lớn về không gian giữa hình ảnh đầu vào và trang phục mục tiêu. Cụ thể, mô hình CP-VTON được xây dựng với cấu trúc gồm 2 môđun như Hình 8.

Cấu trúc mô hình CP-VTON được mô tả như sau:

- 1) Môđun GMM (Geometric Matching Module): mô hình được đào tạo phép biến đổi tấm mỏng spline (thin-plate spline transformation) để thực hiện biến đổi trang phục đầu vào c để khớp với hình dáng cơ thể người được đưa vào là hình ảnh tham chiếu I_i mặc trang phục c_i thông qua môđun GMM thay vì việc tính toán sự tương ứng các điểm trọng yếu như các mô hình trước thời điểm đó từ đó có được trang phục được biến đổi $\hat{c}$.
- 2) Môđun TOM (Try-on Module): Có đầu vào bao gồm trang phục được căn chỉnh $\hat{c}$ và biểu diễn mang tính mô tả của hình ảnh con người với các thông tin về trang phục được loại bỏ p . Môđun này được đưa ra để giảm thiểu các sai lệch ở vùng biên của trang phục

được biến đổi và làm cho kết quả đầu ra chân thực hơn, tác giả đưa ra môđun thử ảo được đào tạo với một mặt nạ bố cục M (được tạo ra bởi mô hình) để hợp nhất trang phục được biến đổi $\hat{c}$ với ảnh được tạo ra I_r và tạo ra hình ảnh tổng hợp I_o để đảm bảo sự mượt mà.

Mô hình được đào tạo với bộ dữ liệu đơn giản (I_i, c, I_t) với ảnh I_t là hình ảnh dữ liệu thực tế (ground truth) của hình ảnh I_o được tạo ra bởi mô hình. Tuy nhiên, việc thu thập tập dữ liệu như được đưa ra ở trên gặp rất nhiều thách thức, một cách tiếp cận dễ dàng hơn khi cho hình ảnh I_i và I_t giống với nhau. Khi đó, ta sẽ có bộ dữ liệu (I_t, c, I_t) hay đơn giản hơn (c, I_t) có thể thu thập dễ dàng. Nhưng việc đào tạo trên tập dữ liệu như vậy sẽ gây hại đến khả năng tạo sinh của mô hình trong quá trình thực nghiệm. Khi đó, một bài viết trước đó [5] khắc phục điều này bằng việc đưa ra một biểu diễn thông tin con người với các thông tin về trang phục được loại bỏ

p (clothing-agnostic person representation) từ đó loại bỏ các ảnh hưởng tiêu cực của trang phục gốc c_i . Từ đó ta có được tập dữ liệu đào tạo mới, cụ thể là (p, c, I_t) . Cách tiếp cận này được sử dụng trong mô hình CP-VTON và sẽ được trình bày chi tiết ở các phần sau.

C. Person Representation

Như đã được đề cập ở phần trước, mô hình CP-VTON sử dụng một phương pháp biểu diễn thông tin con người và loại bỏ các thông tin về trang phục như một phần trong đầu vào của mô hình. Phép biểu diễn ở [5] được đưa ra với mục tiêu loại bỏ sự ảnh hưởng của trang phục ban đầu c_i như thông tin về màu sắc, cấu trúc, và hình dáng trong khi vẫn đảm bảo bảo toàn thông tin về hình ảnh người I_i như các thông tin về mặt, tóc, dáng người, tư thế. Nó bao gồm ba thành phần như Hình 9 sau:

- Bản đồ nhiệt tư thế (pose heatmap): một bản đồ đặc trưng với 18 kênh với tương ứng mỗi kênh là một điểm đặc trưng của tư thế người trong ảnh ban đầu được đặc trưng trong một hình chữ nhật kích thước 11×11 màu trắng.
- Dáng người: mặt nạ nhị phân mờ bao phủ toàn bộ các phần khác nhau của cơ thể con người, từ đó tạo nên đặc trưng về dáng người mà không bị các thông tin trang phục ảnh hưởng.
- Khu vực được bảo toàn: một ảnh màu RGB chứa các vùng được bảo toàn để duy trì các đặc điểm nhận dạng con người cơ bản như mặt và tóc. Khi thực hiện công việc thử ảo thì các vùng này sẽ được ghép vào kết quả cuối cùng để đảm bảo các đặc điểm nhận dạng được bảo toàn sau quá trình thử ảo.



Hình 9. Minh họa biểu diễn con người được mô hình sử dụng

Những bản đồ đặc trưng này được căn chỉnh với kích thước cố định bằng 256×192 và nối liền nhau để tạo thành biểu diễn con người được đề cập p của k kênh, cụ thể $k = 18 + 1 + 3$. Phép biến diễn này được sử dụng như một phần dữ liệu đầu vào cho cả hai mô đun GMM và TOM của mô hình CP-VTON này.

D. Geometric Matching Module Representation (GMM)

Mô hình GMM được dùng để chuyển đổi trang phục đầu vào c thành trang phục được căn chỉnh $\hat{c}$ phù hợp với biểu diễn hình ảnh người đầu vào p .

GMM bao gồm 4 phần như hình 8:

- Hai mạng để trích xuất các đặc trưng cao cấp của p và c tương ứng. Mỗi mạng trích xuất đặc trưng bằng cách sử dụng một loạt các lớp convolutional để tạo ra biểu diễn đặc trưng của ảnh đầu vào. Điều này giúp mã hóa thông tin quan trọng về hình dạng và cấu trúc của người và trang phục.
- Một lớp tương quan để kết hợp hai đặc trưng thành một tensor duy nhất làm đầu vào cho mạng hồi quy. Quá trình này giúp xác định mối quan hệ giữa các đặc trưng của hai hình ảnh, từ đó làm cơ sở cho việc dự đoán các tham số biến đổi không gian.
- Mạng hồi quy để dự đoán các tham số biến đổi không gian θ dựa trên tensor tương quan được tạo ra.
- Sử dụng tham số biến đổi không gian θ dự đoán được từ mạng hồi quy để tạo ra thin-plate spline transformation grid. Điều này cho phép chuyển đổi hình ảnh trang phục ban đầu thành hình ảnh được căn chỉnh $\hat{c} = T_\theta(c)$ phù hợp với hình ảnh người mục tiêu.

Quy trình huấn luyện mô hình GMM có thể thực hiện thông qua việc sử dụng bộ ba mẫu (p, c, c_t) , trong đó p là hình ảnh người đầu vào, c là trang phục đầu vào, và c_t là trang phục mục tiêu trong hình ảnh. Mục tiêu của quá trình huấn luyện là tối ưu hóa hàm mất mát theo pixel $L1$ giữa trang phục được căn chỉnh $\hat{c}$ và trang phục mục tiêu c_t .

Hàm mất mát được biểu diễn như sau:

$$\mathcal{L}_{GMM}(\theta) = \|\hat{c} - c_t\|_1 = \|T_\theta(c) - c_t\|_1 \quad (1)$$

Trong đó, $T_\theta(c)$ là hình ảnh trang phục đã được căn chỉnh sử dụng biến đổi θ được dự đoán bởi mạng hồi quy.

E. Try-on Module

Sau khi có được trang phục đã tinh chỉnh $\hat{c}$ cho phù hợp với hình dáng cơ thể, Try-on Module tiến hành tổng hợp ảnh trang phục và ảnh đối tượng người để tạo ra kết quả là ảnh thử đồ ảo.

Giải pháp đơn giản và dễ nghĩ tới nhất là gán trực tiếp trang phục đã tinh chỉnh $\hat{c}$ lên ảnh đối tượng người. Các chi tiết trên trang phục sẽ được giữ nguyên. Tuy nhiên, việc này sẽ không hiệu quả bởi kết quả trả về không được tự nhiên khi những chi tiết như tóc, tay bị phủ lên hay những chi tiết không phù hợp ở các góc hoặc biên áo. Giải pháp khác là dịch ảnh đầu vào thành ảnh đầu ra thông qua một lần chuyển tiếp mô hình mã hóa - giải mã (encoder-decoder) như UNet, giúp tạo ra ảnh kết quả mượt mà và chân thật hơn. Tuy nhiên, việc có thể căn chỉnh một cách hoàn hảo là không thể, vì thế những điểm tiếp xúc của rìa trang phục và các chi tiết cơ thể sẽ bị mờ.

Mô đun Try-on được đề xuất nhằm kết hợp những lợi ích của cả hai phương pháp đã nói ở trên. Đầu vào là tập các biểu diễn con người p và trang phục đã tinh chỉnh $\hat{c}$, mạng UNet đồng thời tạo 2 đầu ra là ảnh người được chỉnh sửa (chưa hoàn thiện) I_r và một mặt nạ tổng hợp nhị phân M chứa thông tin trang phục và những điểm tránh các chi tiết của người (ví dụ như tóc phủ lên áo) với giá trị 1 là

thông tin cho trang phục và 0 là vùng còn lại. Sau đó, ta thực hiện kết hợp ảnh I_r và ảnh trang phục tinh chỉnh $\hat{c}$ theo mặt nạ M tạo ra kết quả cuối cùng I_o .

$$I_o = M \odot \hat{c} + (1 - M) \odot I_r \quad (2)$$

Trong đó, phép $\odot$ là phép nhân tương ứng các phần tử của ma trận.

Trong giai đoạn huấn luyện cho mô đun Try-on, với đầu vào là (p, c, I_t) , mục tiêu là tối thiểu sự khác biệt của ảnh do mô đun tạo ra I_o và ảnh xác thực I_t . Mô hình sẽ sử dụng hàm mất mát phổ biến là $L1$ và hàm mất mát cảm quan VGG (VGG Perceptual Loss), như bên dưới: c Với $\phi_i(I)$ là bản đồ đặc trưng của ảnh I tại lớp thứ i của mô hình mạng nhận thức hình ảnh (visual perceptron network) ϕ , cụ thể là mạng VGG19 đã được huấn luyện trên dữ liệu ImageNet.

Mục tiêu của chúng ta là giữ những chi tiết trên trang phục, vì thế chúng ta sẽ ưu tiên mặt nạ tổng hợp M ở phía trên chọn càng nhiều vùng trang phục càng tốt. Cuối cùng, hàm mất mát sẽ trông như sau:

$$\mathcal{L}_{TOM} = \lambda_{L1} \|I_o - I_t\|_1 + \lambda_{vgg} \mathcal{L}_{VGG}(\hat{I}, I) + \lambda_{mask} \|1 - M\|_1 \quad (3)$$

IV. EXPERIMENTS

A. Dataset

Bộ dữ liệu chuẩn VITON được chuyển đổi thành cách thư mục khác nhau để sử dụng. Ngoài ảnh trang phục và ảnh người mẫu thì các thư mục còn lại được biến đổi để tạo ra dữ liệu học. Các thư mục mới bao gồm: mặt nạ của trang phục, bản đồ phân đoạn của người mẫu và tập tin JSON chứa các điểm đánh dấu của cơ thể người mẫu.

Cấu trúc tập dữ liệu

- cloth: Dữ liệu hình ảnh trang phục sử dụng cho mô hình thử ảo.
- cloth-mask: Chứa các mặt nạ được tạo ra từ các ảnh áo trong dữ liệu trang phục. Mặt nạ này được tạo ra để phân biệt hình dạng của trang phục, hay cụ thể hơn vùng áo và nền của áo trong quá trình xử lý dữ liệu.
- image: Chứa ảnh của những người mẫu mặc trang phục.
- image-parse: Chứa các bản đồ phân đoạn của ảnh người mẫu tương ứng với từ dữ liệu trong tập dữ liệu hình ảnh. Bản đồ phân đoạn này được sử dụng để nhận diện và phân loại các phần khác nhau của cơ thể con người như khuôn mặt, tay, chân, phần thân trên, thân dưới, ...
- pose: Chứa thông tin về điểm đánh dấu của cơ thể trong dạng tệp JSON. Các thông tin này có thể bao gồm vị trí các điểm mốc trên cơ thể như các điểm đầu gối, đầu vai, vv. Từ đó xác định được tư thế của con người trong hình ảnh đầu vào.



Hình 10. Một số hình ảnh minh họa của tập dữ liệu

B. Implementation Details

1) *Thiết lập quá trình huấn luyện*: Các tham số được xác định như sau: $\lambda_{L1} = \lambda_{vgg} = 1$, khi mặt nạ bố cục được sử dụng, $\lambda_{mask} = 1$.

Trong quá trình thực thi huấn luyện, vì giới hạn phần cứng nên việc thực hiện sẽ được thiết lập nhau sau, bao gồm

- 100 ngàn epochs.
- Kích thước batch bằng 4.
- Các tham số Adam: $\beta_1 = 0.5$ và $\beta_2 = 0.999$.
- Tốc độ học hay Learning rate ban đầu được thiết lập là 0.0001 và phân rã tuyến tính dần về 0.
- Các hình ảnh được cố định kích thước 256×192 và có cùng độ phân giải.

2) *Geometric Matching Module (GMM)*: Mô đun khớp hình học GMM chịu trách nhiệm khớp (căn chỉnh cấu trúc) trang phục với cơ thể người một cách chính xác. Nó bao gồm hai mạng nơ-ron: mạng trích xuất đặc trưng và mạng hồi quy.

Mạng trích xuất đặc trưng trích xuất đặc trưng từ cả biểu diễn con người và trang phục và chúng có cùng cấu trúc với nhau:

- Sử dụng cấu trúc mạng nơ-ron tương tự nhau với 4 lớp tích chập lấy mẫu xuống 2 bước.
- Kích thước bộ lọc của các lớp lần lượt là 64, 128, 256, 512, 512.
- Sự khác biệt duy nhất giữa hai mạng là số lượng kênh đầu vào.

Mạng hồi quy: dự đoán các tham số của phép biến đổi Thin-Plate Spline (TPS) để khớp (căn chỉnh cấu trúc) trang phục với cơ thể người:

- Bao gồm 2 lớp tích chập 2 bước, 2 lớp tích chập 1 bước và một lớp đầu ra kết nối đầy đủ.
- Số lượng bộ lọc của các lớp lần lượt là 512, 256, 128, 64.
- Lớp kết nối đầy đủ dự đoán độ lệch tọa độ x và y của các điểm neo trong phép biến đổi TPS, do đó có kích thước đầu ra là $2 \times 5 \times 5 = 50$

3) *Try-on Module (TOM)*: Mô-đun thử trang phục (TOM) chịu trách nhiệm tổng hợp hình ảnh cuối cùng sau khi khớp trang phục với cơ thể người. Nó sử dụng mô hình mạng UNet 12 lớp với 6 lớp tích chập lấy mẫu xuống 2 bước và 6 lớp tích chập lấy mẫu lên.

Để giảm thiểu hiện tượng "checkerboard artifacts", mô-đun TOM sử dụng:

- Sự kết hợp của lớp nội suy láng giềng gần nhất và lớp tích chập 1 bước cho việc lấy mẫu lên thay vì lớp giải mã 2 bước thường được sử dụng.
- Phương pháp này được đề cập trong bài báo [9].

Số lượng bộ lọc của các lớp tích chập:

- Lấy mẫu xuống: 64, 128, 256, 512, 512, 512.
- Lấy mẫu lên: 512, 512, 256, 128, 64, 4.

C. Thực nghiệm và đánh giá kết quả

Các kết quả sau đây được thực nghiệm trong mô hình với hai mô-đun GMM và TOM được huấn luyện với 100 nghìn epochs, vì vậy các kết quả có thể thể hiện không chính xác mức độ tốt nhất của mô hình.

1) *Mô-đun GMM*: Mô-đun này nhằm thực hiện quá trình căn chỉnh trang phục phù hợp với hình dáng cơ thể của con người trong hình ảnh được đưa vào mô hình, do đó ở đây ta thực hiện đánh giá tổng quát như sau:

- Đối với các trang phục đơn giản (áo trơn, không có họa tiết) mô hình thực hiện khá tốt việc căn chỉnh.
- Đối với trang phục có họa tiết phức tạp (hình vẽ, chữ, ...) mô hình gặp khó khăn trong việc căn chỉnh.



Hình 11. Kết quả thực nghiệm GMM

D. Mô-đun TOM

Ta thực hiện đánh giá các kết quả dựa trên đánh giá chủ quan. Ta sẽ nhìn ảnh và đánh giá, dựa trên các tiêu chí về mức độ phù hợp, độ chân thật cũng như mức độ bảo toàn các chi tiết của trang phục. Ta xét thang đo như sau:

- Điểm 5: Rất chân thật

- Điểm 4: Có những sai sót nhỏ
- Điểm 3: Thiếu họa tiết
- Điểm 2: Trông không thực, có nhiều chi tiết lỗi
- Điểm 1: Lộn xộn, không có chi tiết nào được bảo toàn.

Dựa theo kết quả có thể thấy, với những trang phục có họa tiết đơn giản như áo đơn sắc, các kết quả trả về trông khá chân thật, có thể trên thang điểm 4 hoặc 5. Ngược lại, với những ảnh có họa tiết như sọc, vân thì ảnh bị nhòe mờ ở vài điểm, có thể trên thang điểm 3. Với những ảnh có tay bắt chéo hay vùng áo bị che nhiều bởi các chi tiết cơ thể, kết quả trả về bị nhòe, nhiễu và mất nhiều chi tiết cơ thể và quần áo. Tuy nhiên, vẫn có thể nhìn ra được vùng trang phục ướm thử, nên có thể chấm trên thang 2 điểm. Rất ít trường hợp kết quả được đánh giá trên thang 1 điểm, cho thấy mức ổn định của mô hình.



Hình 12. Kết quả thực nghiệm TOM

V. CONCLUSION AND FUTURE DEVELOPMENTS

A. Tổng kết về mô hình CP-VTON


Phương pháp được đưa ra là một mô hình thử đồ ảo dựa trên hình ảnh có thể đào tạo hoàn toàn với mục tiêu bảo toàn các đặc trưng của trang phục được gọi là CP-VTON cụ thể bao gồm một mô-đun kết hợp hình học mới, một mô-đun thử đồ ảo với chiến lược kết hợp mới. Hiệu suất của mô hình tại thời điểm đó được chứng minh vượt trội so với các thời điểm cùng thời thông qua các thực nghiệm mở rộng trên tập dữ liệu của [5].

B. Đề xuất cải tiến mô hình

Trong mô hình CP-VTON, ở mô-đun GMM, tác giả ban đầu chỉ sử dụng một hàm mất mát $\mathbb{L}_1$ giữa trang phục

được căn chỉnh bởi mô hình với trang phục được lấy từ hình ảnh đầu vào để cải thiện mô hình qua các epoch. Khi này, để cải thiện khả năng điều chỉnh các tham số của mô hình ta sử dụng thêm một hàm mất mát L1 giữa hình ảnh con người ban đầu lần lượt ghép với trang phục được căn chỉnh bởi mô hình và trang phục được lấy từ hình ảnh đầu vào. Khi đó ta xác định được hàm mất mát cho mô hình:

$$\mathcal{L}_{nGMM}(\theta) = 0.5 \times \|\hat{c} - c_t\|_1 + \|p\hat{c} - pc_t\|_1 \quad (4)$$



Hình 13. Minh họa mô hình mới với việc thêm Loss L1

C. Đánh giá kết quả dựa trên mô hình được cải tiến

Trong phần này, nhóm đánh giá kết quả dựa trên mô hình được cải tiến trong hệ thống thử đồ ảo (virtual try-on). Cụ thể, nhóm đã tiến hành cải tiến hàm loss tại GMM model và so sánh kết quả với mô hình gốc.

- Hiệu suất tổng thể: Mặc dù sự cải thiện về giá trị loss là nhỏ, nó vẫn cho thấy rằng hướng cải tiến này có tiềm năng. Điều này có thể gợi ý rằng hàm loss đã được cải tiến có thể giúp mô hình học tốt hơn một số khía cạnh nhất định của dữ liệu.
- Chất lượng hình ảnh: Nhóm cũng tiến hành đánh giá trực quan chất lượng hình ảnh đầu ra từ mô hình. Các hình ảnh thử nghiệm cho thấy sự cải thiện nhỏ nhưng rõ ràng về độ chính xác của việc ghép quần áo và hình ảnh người mẫu.

TÀI LIỆU

- [1] Y. G. H. Y. W. L. P. L. Chongjian Ge, Yibing Song, “Dcton: Disentangled cycle consistency for highly-realistic virtual try-on,” 2021. 1
- [2] K. Yan, T. Gao, H. Zhang, and C. Xie, “Sal-vton: Linking garment with person via semantically associated landmarks for virtual try-on,” in *Proceedings of the 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2023. 2
- [3] A. Cui, D. McKee, and S. Lazebnik, “Dressing in order: Recurrent person image generation for pose transfer, virtual try-on and outfit editing,” 2022. 2
- [4] S. Choi, S. Park, M. Lee, and J. Choo, “Viton-hd: High-resolution virtual try-on via misalignment-aware normalization,” 2021. 3
- [5] X. Han, Z. Wu, Z. Wu, R. Yu, and L. S. Davis, “Viton: An image-based virtual try-on network,” 2018. 3, 4, 5, 6, 8
- [6] L. Zhu, D. Yang, T. Zhu, F. Reda, W. Chan, C. Saharia, M. Norouzi, and I. Kemelmacher-Shlizerman, “Tryondiffusion: A tale of two unets,” 2023. 3
- [7] T. Islam, A. Miron, X. Liu, and Y. Li, “Deep learning in virtual try-on: A comprehensive survey,” *IEEE Access*, vol. 12, pp. 29 475–29 502, 2024. 4

- [8] D. Song, X. Zhang, J. Zhou, W. Nie, R. Tong, M. Kankanhalli, and A.-A. Liu, “Image-based virtual try-on: A survey,” 2023. 4
- [9] A. Odena, V. Dumoulin, and C. Olah, “Deconvolution and checkerboard artifacts,” *Distill*, 2016. [Online]. Available: <http://distill.pub/2016/deconv-checkerboard/> 8